Un dataset italiano per l'analisi degli stereotipi di genere nei testi mediante Large Language Models

Elisa Famulari

13 Marzo 2026

Sommario

Il presente lavoro analizza un dataset italiano per lo studio degli stereotipi di genere nei testi mediante il confronto tra attribuzioni umane aggregate e output di tre Large Language Models (GPT, Gemini e DeepSeek). L'analisi si basa su punteggi continui di gender-score assegnati alle stesse sezioni testuali, consentendo un confronto quantitativo tra distribuzioni e un'analisi correlazionale dei pattern di attribuzione. I risultati evidenziano che i modelli non operano in uno spazio semantico distinto rispetto alla percezione umana, ma condividono un nucleo comune di associazioni. Le differenze emergono principalmente nella dispersione dei punteggi e nella soglia con cui le polarizzazioni vengono esplicitate: alcuni modelli mostrano una maggiore tendenza alla neutralizzazione in presenza di ambiguità, mentre altri esprimono più facilmente polarizzazioni in corrispondenza di segnali semanticamente connotati.

L'analisi qualitativa dei casi di disallineamento individua pattern ricorrenti legati a dominio tematico, salienza lessicale e ambiguità strutturale. I risultati suggeriscono che la valutazione del bias nei Large Language Models richieda di considerare non solo la direzione delle attribuzioni, ma anche la calibrazione e l'intensità della loro espressione.

1 Introduzione

L'analisi degli stereotipi di genere nei testi costituisce un ambito di crescente interesse nell'intersezione tra linguistica, scienze sociali e intelligenza artificiale. Con la diffusione dei Large Language Models (LLM), diventa rilevante indagare in che misura tali sistemi riproducano, modulino o attenuino associazioni di genere presenti nei dati di addestramento e nella cultura linguistica di riferimento.

Il presente studio si colloca in continuità con la ricerca accademica italiana sul tema. Scagnet (2023) ha sviluppato e validato un dataset in lingua italiana attraverso valutazione umana, introducendo una misura continua di gender score per quantificare la percezione del pubblico di riferimento implicito nei testi. Friso (2022) ne ha esplorato l'applicazione analitica. Successivamente, Vismara (2024) ha utilizzato tale dataset come base per generare un corpus di risposte prodotte da un modello linguistico, creando così un nuovo insieme di testi modellistici non sottoposto a validazione percettiva umana.

La presente ricerca prende avvio da questo corpus modellistico: i testi generati e raccolti da Vismara (2024) vengono sottoposti a valutazione umana mediante questionario, al fine di ottenere un riferimento percettivo aggregato finora assente. Il medesimo insieme di testi viene inoltre proposto a ulteriori modelli linguistici generativi (GPT, Gemini e DeepSeek), ai quali è richiesto di attribuire un gender score secondo la medesima scala.

L'obiettivo non è la costruzione di un nuovo dataset, bensì la realizzazione di un confronto sistematico, su base comune e controllata, tra valutazione umana e attribuzioni modellistiche multiple, così da analizzarne convergenze, divergenze e possibili tendenze strutturali.

L'attenzione si concentra non solo sulla direzione della polarizzazione, ma anche sull'intensità e sulla dispersione dei punteggi, con l'intento di valutare se i modelli operino in uno spazio semantico sovrapponibile alla percezione umana o se emergano differenze nel modo in cui le associazioni di genere vengono espresse.

2 Background teorico

2.1 Stereotipi di genere e linguaggio

In ambito psicologico-sociale, gli stereotipi possono essere definiti come rappresentazioni cognitive semplificate e condivise, attraverso cui vengono attribuite caratteristiche generalizzate ai membri di un determinato gruppo sociale. Tali rappresentazioni svolgono una funzione di organizzazione della realtà, consentendo di classificare e interpretare rapidamente le informazioni sociali; tuttavia, esse possono cristallizzarsi in forme rigide, contribuendo alla costruzione di aspettative normative nei confronti dei gruppi stessi [15].

Nel caso del genere, gli stereotipi assumono una particolare rilevanza, in quanto riferiti a una delle principali categorie di identificazione sociale. Le disuguaglianze di genere continuano infatti a rappresentare una dimensione strutturale delle società contemporanee. Il *Global Gender Gap Report* del World Economic Forum evidenzia come persistano differenze significative tra uomini e donne in ambiti quali partecipazione economica, accesso alle opportunità e rappresentanza politica. Tali evidenze suggeriscono che le disparità di genere non costituiscano un fenomeno marginale o superato, ma una realtà ancora attuale su scala globale. [8]

La formazione e la stabilizzazione degli stereotipi di genere possono essere ricondotte ai processi di categorizzazione sociale descritti dalla *Social Identity Theory*.

Tajfel sottolinea come gli individui tendano a distinguere tra ingroup e outgroup, attribuendo ai membri di ciascun gruppo tratti omogenei e distintivi. Questo processo, pur rispondendo a un'esigenza cognitiva di semplificazione, può favorire la costruzione di rappresentazioni generalizzate e durature [15]. Nel caso specifico del genere, tali rappresentazioni risultano strettamente connesse alla distribuzione storica dei ruoli sociali. La teoria dei ruoli sociali proposta da Eagly e Wood evidenzia come le differenze attribuite a uomini e donne derivino in larga misura dalla divisione del lavoro e delle responsabilità all'interno della società, contribuendo a consolidare aspettative su competenze, comportamenti e ambiti di attività considerati appropriati per ciascun genere [5]

Queste rappresentazioni non rimangono circoscritte alla dimensione comportamentale o istituzionale, ma trovano espressione anche nel linguaggio. Nell'ambito della *Critical discourse analysis*, Fairclough definisce il discorso come una forma di pratica sociale, sostenendo che il linguaggio non si limita a descrivere la realtà, ma contribuisce alla costruzione e alla riproduzione di ideologie e relazioni di potere [6].

In questa prospettiva, il linguaggio non è un mero veicolo di informazioni, ma un deposito strutturato di bias sociocognitivi in cui le associazioni tra determinati contenuti, registri o ambiti tematici e un'identità di genere si manifestano come espressioni di rappresentazioni sociali condivise. Così, ad esempio, tematiche legate alla sfera emotiva o relazionale possono essere culturalmente percepite come più coerenti con il femminile, mentre ambiti tecnico-scientifici o razionali vengono più facilmente associati al maschile. L'analisi dei testi consente pertanto di osservare come tali attribuzioni emergano e vengano implicitamente proiettate su un'identità di genere, rendendo il materiale linguistico un terreno privilegiato per indagare come gli stereotipi vengano codificati, elaborati e restituiti tanto dai parlanti quanto dai modelli computazionali.

2.2 Bias nei modelli linguistici

L'architettura *Transformer*, introdotta da Vaswani et al. (2017), è un modello neurale per l'elaborazione di sequenze basato esclusivamente su meccanismi di self-attention, progettato per apprendere relazioni contestuali tra token all'interno di un testo. A differenza delle precedenti architetture ricorrenti o convoluzionali, il Transformer consente di modellare dipendenze a lungo raggio in modo parallelo ed efficiente, superando i limiti di scalabilità dei sistemi precedenti. Grazie alla combinazione di self-attention multi-head, rappresentazioni distribuzionali e addestramento su larga scala, tale architettura è divenuta la base per lo sviluppo dei successivi Large Language Models (LLM). [16] I LLM sono tipicamente pre-addestrati su corpora testuali di ampia scala mediante obiettivi autoregressivi o di masked language modeling, apprendendo a predire il token successivo o a ricostruire parti mancanti di una sequenza. Attraverso questo processo, il modello costruisce spazi vettoriali ad alta dimensionalità in cui parole, frasi e concetti sono rappresentati sulla base delle loro co-occorrenze statistiche. In tale quadro, il modello non acquisisce conoscenze semantiche in senso intenzionale, ma apprende regolarità distribuzionali presenti nei dati di addestramento.

Il bias nei modelli linguistici può essere analizzato su tre livelli distinti ma interconnessi. In primo luogo, è possibile individuare un bias statistico, derivante dalle distribuzioni presenti nei dati di addestramento e dalle associazioni co-occorrenti apprese durante il pre-training. In secondo luogo, si può parlare di bias algoritmico, legato alle dinamiche di ottimizzazione e ai meccanismi attraverso cui il modello generalizza tali distribuzioni. Infine, nei modelli contemporanei, assume un ruolo rilevante il bias di policy o di alignment, introdotto dalle fasi di fine-tuning e dalle strategie di mitigazione orientate alla sicurezza e alla conformità normativa. Per quanto riguarda il primo livello, il bias statistico può essere ricondotto ai dati di addestramento. Corpora di grandi dimensioni, spesso raccolti dal web, riflettono inevitabilmente squilibri, asimmetrie e stereotipi presenti nella società. Studi sui word embeddings hanno mostrato come associazioni di genere latenti nei dati possano emergere in forma di correlazioni misurabili tra termini, ad esempio tra professioni e genere [4]. Analisi analoghe nel contesto linguistico italiano hanno confermato la presenza di pattern simili anche in corpora nazionali [3]. Sebbene tali studi si riferiscano a modelli distribuzionali statici, il principio rimane valido per i modelli basati su Transformer: le rappresentazioni interne riflettono e codificano le distribuzioni statistiche del corpus di addestramento. Accanto al bias nei dati, è possibile individuare una dimensione algoritmica. L'ottimizzazione mediante gradient descent mira a massimizzare la probabilità dei token osservati nel corpus, rafforzando le associazioni più frequenti. In presenza di squilibri sistematici nei dati, tale meccanismo può contribuire alla propagazione o all'amplificazione di determinate correlazioni. Inoltre, l'aumento della scala del modello e del dataset può favorire l'emergere di comportamenti non lineari o generalizzazioni inattese, fenomeni spesso descritti come effetti emergenti nei LLM e oggetto di riflessione critica in letteratura [2].

Tali dinamiche strutturali non esauriscono tuttavia la spiegazione del comportamento osservabile nei modelli contemporanei, poiché le fasi successive di fine-tuning e allineamento introducono ulteriori livelli di modulazione dell'output. In questa prospettiva, il bias nei modelli Transformer non va inteso come espressione di intenzionalità, ma come effetto emergente delle distribuzioni statistiche apprese e delle dinamiche di ottimizzazione. L'analisi empirica delle risposte generate dai modelli consente quindi di osservare in che misura le associazioni stereotipate e le aspettative normative descritte nel capitolo precedente vengano riprodotte, attenuate o amplificate nei sistemi generativi contemporanei.

2.3 Alignment e strategie di mitigazione nei LLM

Nel contesto dei Large Language Models (LLM), il termine *alignment* indica l'insieme di tecniche volte a rendere il comportamento del modello coerente con va-

lori normativi, linee guida etiche e aspettative sociali. I modelli linguistici di grandi dimensioni vengono inizialmente pre-addestrati su corpora testuali di ampia scala mediante obiettivi puramente statistici, come la predizione del token successivo o la ricostruzione di sequenze. In questa fase il modello apprende distribuzioni linguistiche presenti nei dati, senza incorporare intenzionalmente criteri valutativi o principi normativi [2]. Le tecniche di alignment intervengono in una fase successiva al pre-training e hanno l'obiettivo di modulare l'output generato, riducendo la probabilità di produrre contenuti dannosi o discriminatori [11, 1].

Una delle strategie più diffuse nei modelli proprietari è il Reinforcement Learning from Human Feedback (RLHF). In questo paradigma, annotatori umani valutano diverse risposte generate dal modello rispetto a uno stesso prompt, esprimendo preferenze qualitative. Tali preferenze vengono utilizzate per addestrare un modello di ricompensa che stima quali risposte risultino maggiormente desiderabili secondo i criteri stabiliti. Il modello linguistico viene quindi ulteriormente ottimizzato tramite tecniche di reinforcement learning per massimizzare tale ricompensa [11]. Questo processo non elimina le associazioni apprese durante il pre-training, ma può attenuarne o riorientarne l'espressione nei contesti generativi.

Accanto al RLHF, molti LLM vengono sottoposti a fine-tuning supervisionato su dataset annotati manualmente, costruiti per incoraggiare comportamenti ritenuti appropriati e scoraggiare risposte problematiche [11]. Tale fase consente di adattare un modello generico a criteri più specifici di qualità e sicurezza, intervenendo sulla distribuzione delle risposte senza modificarne l'architettura neurale di base.

Le strategie di alignment sono frequentemente integrate da policy di safety multilivello, che possono includere filtri automatici, classificatori di contenuto e linee guida interne di moderazione [18, 10]. Tali meccanismi mirano a prevenire la generazione di contenuti offensivi o discriminatori e rappresentano una componente centrale nella distribuzione pubblica dei modelli su larga scala.

Le tecniche di alignment possono influenzare non soltanto la rimozione di contenuti esplicitamente problematici, ma anche la distribuzione complessiva delle risposte generate. In compiti che richiedono la valutazione di contenuti connotati socialmente, tali interventi potrebbero tradursi in una tendenza alla moderazione o alla neutralizzazione delle categorie estreme, incidendo sull'intensità delle attribuzioni. Una riduzione della polarizzazione osservabile negli output non implica necessariamente l'assenza di associazioni statistiche interne, ma può essere interpretata come effetto della modulazione introdotta dalle fasi di alignment [2, 11].

I modelli linguistici possono inoltre essere sviluppati secondo paradigmi differenti di governance e distribuzione. I sistemi proprietari tendono a integrare procedure strutturate di alignment accompagnate da documentazione pubblica sulle policy di utilizzo e sicurezza [10, 7], mentre i modelli open-source o semi-open possono presentare maggiore variabilità nelle strategie di fine-tuning e nei meccanismi di controllo implementati [9]. Inoltre, le differenti aree di sviluppo dei modelli e i contesti regolatori (come nel caso del confronto tra sistemi statunitensi e asiatici) possono influenzare le priorità di allineamento. Tali differenze non consentono di stabilire a priori un diverso livello di bias, ma costituiscono un elemento rilevante nel contestualizzare eventuali divergenze comportamentali osservate in analisi comparative.

Tali differenze strutturali e di governance costituiscono il quadro interpretativo entro cui verranno letti i risultati empirici.

È opportuno precisare che, nel caso dei modelli proprietari, i dettagli completi relativi alla composizione dei dataset di addestramento e alle pipeline di fine-tuning non sono pubblicamente accessibili [2, 9]. Di conseguenza, l'analisi proposta nel presente lavoro non può assumere carattere causale rispetto alle singole strategie di alignment implementate, ma si basa sull'osservazione comparativa del comportamento dei modelli in fase di output.

3 Metodologia

3.1 Costruzione del dataset

Il dataset impiegato nel presente studio deriva dal corpus utilizzato nello studio pilota di Vismara (2024), in cui i testi erano suddivisi in tre categorie — maschile, femminile e neutra — sulla base della tipologia delle fonti e del pubblico di riferimento dichiarato. La classificazione delle categorie era definita a priori e non era stata oggetto di una validazione sistematica tramite valutazione percettiva umana.

Al fine di incrementare la numerosità campionaria e consentire un'analisi comparativa più robusta, il dataset è stato ampliato mantenendo invariata l'impostazione concettuale originaria. Il corpus finale è composto da 180 porzioni testuali in lingua italiana, suddivise uniformemente in 60 testi per ciascuna categoria.

I nuovi estratti sono stati selezionati secondo criteri coerenti con il corpus originario in termini di lunghezza (30–80 parole), tipologia di contenuto e registro linguistico, preservando l'equilibrio tematico tra le categorie. La distribuzione perfettamente bilanciata tra le classi è stata mantenuta al fine di evitare distorsioni nelle analisi statistiche successive e garantire confronti controllati tra le categorie. L'ampliamento non ha modificato la definizione operativa delle 3 categorie, che è rimasta coerente con quella adottata nello studio originale.

Il dataset completo, unitamente agli script di analisi, è reso disponibile pubblicamente tramite repository GitHub, al fine di assicurare trasparenza metodologica e replicabilità dello studio.

3.2 Valutazione umana del dataset

La valutazione umana è stata condotta adottando la struttura metodologica descritta da Scagnet (2023) [12], applicandola al dataset derivato da Vismara (2024) [17].

Ai partecipanti è stato richiesto di rispondere alla seguente domanda:

"A quale genere pensa che il testo sia rivolto?"

La valutazione è stata espressa mediante una scala discreta bipolare a cinque livelli, operativamente codificati come $\{-2, -1, 0, +1, +2\}$ ai fini dell'analisi statistica, accompagnata dalle seguenti etichette verbali:

- $-2 \rightarrow$ Completamente femminile
- $-1 \rightarrow$ Più femminile che maschile
- $0 \rightarrow$ Neutro
- $+1 \rightarrow$ Più maschile che femminile
- $+2 \rightarrow$ Completamente maschile

Indipendentemente dalla scala, il partecipante aveva la possibilità di selezionare un'opzione aggiuntiva di non risposta. Le risposte mancanti sono state escluse dalle analisi.

La scala, simmetrica rispetto allo zero, consente di misurare la percezione del pubblico di riferimento implicito lungo un continuum femminile–maschile, rilevandone direzione e intensità.

Il questionario è stato somministrato tramite la piattaforma online *PsyToolkit*, utilizzata per la creazione e la gestione di questionari sperimentali. [13] [14] ; i testi sono stati presentati in ordine randomizzato e ciascun partecipante ha valutato un sottoinsieme del corpus, al fine di ridurre effetti di affaticamento e bias di ordine.

Il questionario è stato inizialmente compilato da 106 partecipanti. A seguito dell'esclusione dei questionari incompleti, dei soggetti che non hanno superato le domande di controllo e di un caso con tempo di compilazione inferiore alla soglia minima stabilita (4 minuti), il campione finale analizzato è risultato composto da 75 partecipanti.

Il campione presenta una distribuzione di genere relativamente bilanciata (56% femminile, 41.3% maschile, restante percentuale non specificata o altro). La maggior parte dei partecipanti appartiene alla fascia di età 18–30 anni, configurando un campione prevalentemente giovane. L'82.7% dei soggetti si dichiara madrelingua italiana e il 98.7% di nazionalità italiana. Tale composizione garantisce omogeneità linguistica nella valutazione dei testi.

Un'ulteriore domanda sottoposta ai partecipanti riguardava la percezione della difficoltà nel compilare il questionario: il 48% dei partecipanti ha risposto "sì, in qualche caso", il 41.3% "No" e il restante "Sì, nella maggior parte dei casi". Complessivamente, il questionario risulta pertanto generalmente comprensibile e adeguato al livello del campione analizzato.

Al fine di garantire stabilità statistica nel calcolo dei punteggi medi, sono state escluse le sezioni che presentavano meno di cinque valutazioni indipendenti. L'analisi umana è stata pertanto condotta su 111 sezioni valide.

3.3 Protocollo di valutazione dei modelli

L'intero corpus ampliato di 180 porzioni testuali è stato sottoposto a tre modelli linguistici generativi: *GPT-4.1-mini*, *Gemini-2.5-flash* e *DeepSeek-chat*. La scelta di utilizzare versioni "mini" o "flash", anziché versioni di fascia superiore, è stata motivata dalla natura del task sperimentale. Poiché l'operazione richiesta consiste in una classificazione discreta su scala limitata, l'impiego di modelli più complessi avrebbe comportato un incremento dei costi computazionali senza un beneficio proporzionato rispetto alla complessità dell'operazione richiesta. L'utilizzo di modelli appartenenti alla medesima fascia applicativa consente inoltre un confronto più omogeneo tra sistemi sviluppati secondo differenti strategie di addestramento e governance.

La selezione è stata altresì guidata da criteri di rilevanza applicativa e diversità di sviluppo: GPT e Gemini rappresentano attualmente due tra i sistemi generativi più diffusi a livello internazionale, costituendo un riferimento consolidato nel panorama proprietario. L'inclusione di DeepSeek, modello di più recente introduzione sviluppato in un differente contesto geografico e strategico, permette di estendere il confronto a sistemi non riconducibili esclusivamente al contesto statunitense, introducendo una dimensione comparativa anche sul piano della governance.

Per garantire piena comparabilità tra i modelli è stata implementata un'unica pipeline in linguaggio Python, resa disponibile nel repository GitHub del progetto. Lo script è strutturato in modo parametrico e consente di selezionare esplicitamente provider e modello tramite argomenti da riga di comando (ad esempio `-provider` e `-model`).

L'autenticazione ai diversi provider avviene tramite chiavi API impostate come variabili d'ambiente. Tali chiavi permettono l'autorizzazione della richiesta verso l'endpoint del modello selezionato, senza influenzarne il comportamento generativo. Una volta specificati provider e parametri di esecuzione, lo script effettua una chiamata API autenticata, riceve la risposta del modello e procede alla validazione e al salvataggio dell'output in formato strutturato, garantendo tracciabilità e replicabilità dell'esperimento.

A titolo esemplificativo, una delle esecuzioni è stata avviata mediante il seguente comando:

```
python gender_survey_pipeline.py run \
  --dataset dataset2_Survey_cleaned.csv \
  --provider gemini \
  --model gemini-2.5-flash \
  --temperature 0.5 \
  --max_output_tokens 64 \
  --retries 6 \
  --output results_gemini_t05_run2.csv
```

La domanda sottoposta ai modelli era identica a quella rivolta ai partecipanti umani ("A quale genere pensa che il testo sia rivolto?"). Il prompt richiedeva esplicitamente la restituzione di un unico valore numerico appartenente all'insieme $\{-2, -1, 0, +1, +2\}$ ed è stato usato il medesimo per tutti i modelli senza variazioni lessicali. L'output è stato vincolato a formato numerico, al fine di evitare generazioni discorsive o ambigue e garantire piena coerenza con la scala utilizzata nel questionario umano.

Per ciascun modello sono state effettuate cinque esecuzioni complessive (run), così distribuite: una run a

temperatura $T = 0$, due run a $T = 0.3$ e due run a $T = 0.5$. La distribuzione non uniforme delle run riflette l'interesse a valutare la stabilità del modello in condizioni sia deterministiche (T=0) sia moderatamente stocastiche (T=0.3 e T=0.5). La temperatura controlla il grado di aleatorietà del processo di campionamento dei token: valori più elevati aumentano la probabilità di selezionare alternative meno probabili, incrementando la variabilità dell'output.

Nel presente studio non sono state considerate temperature superiori a 0.5 (ad esempio $T = 1$, impiegata nello studio preliminare di Vismara), in quanto livelli più elevati avrebbero introdotto una componente stocastica eccessiva rispetto alla natura classificatoria e discreta del task, compromettendo la stabilità comparativa delle risposte. In un task classificatorio discreto, l'effetto della temperatura si manifesta principalmente nella scelta tra valori prossimi in condizioni di ambiguità.

Le cinque run per ciascun provider sono state aggregate in un'unica tabella strutturata, nella quale a ogni porzione testuale corrispondeva una riga contenente le cinque valutazioni generate dal modello, con indicazione della temperatura associata a ciascuna esecuzione. A partire da tale struttura sono stati calcolati, per ogni sezione testuale, il punteggio medio aritmetico, la deviazione standard tra le esecuzioni e la discrepanza rispetto alla classificazione a priori.

Sebbene l'elaborazione sia stata effettuata sull'intero corpus di 180 testi per completezza e riutilizzabilità futura del dataset, il confronto diretto con la valutazione umana è stato condotto sulle 111 sezioni valide, in coerenza con il filtraggio applicato ai dati del questionario.

4 Risultati

4.1 Percezione umana

L'analisi complessiva dei gender score assegnati dai partecipanti evidenzia una media globale pari a -0.012, valore sostanzialmente neutro. La deviazione standard è pari a 0.639, con un intervallo osservato compreso tra -1.80 e 1.73.

L'assenza di uno scostamento significativo dalla neutralità indica che il campione, nel suo insieme, non manifesta una polarizzazione sistematica verso una delle due polarità di genere. Tuttavia, l'ampiezza del range osservato mostra che alcune sezioni vengono percepite come fortemente connotate, sia in senso femminile sia maschile, segnalando una distribuzione ampia e non compressa attorno allo zero (Figura 1).

Tabella 1: Statistiche descrittive per categoria testuale (valutazione umana)

Categoria	N sezioni	Score medio	Deviazione std
F	41	-0.395	0.512
M	39	0.446	0.628
N	31	-0.081	0.409

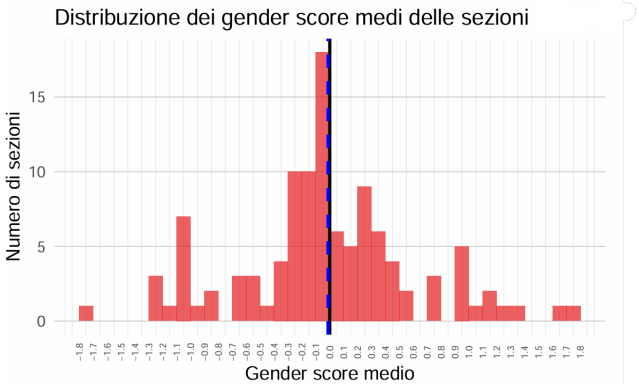

Figura 1: Distribuzione dei gender score medi delle sezioni valutate. La linea verticale indica lo zero della scala [-2, +2].

L'analisi disaggregata (Tabella 1) evidenzia una chiara separazione tra le categorie femminile e maschile. I testi femminili presentano una media negativa stabile (-0.395), mentre i testi maschili mostrano una polarizzazione positiva di entità analoga (0.446). I testi neutri si collocano in prossimità dello zero (-0.081), confermando la coerenza della struttura tripartita del dataset. La dispersione è più elevata nella categoria maschile (0.628), suggerendo una maggiore variabilità interpretativa rispetto ai testi femminili (0.512) e ai testi neutri (0.409), che risultano la categoria più stabile. Nel complesso, la percezione collettiva distingue nettamente le polarità principali, mantenendo la neutralità come area intermedia coerente. Accanto alla coerenza generale emergono tuttavia casi di disallineamento rispetto alla categorizzazione teorica. In particolare:

- 11 testi femminili su 41 (27%) presentano uno score medio maggiore o uguale a zero;
- 10 testi maschili su 39 (26%) presentano uno score medio minore o uguale a zero.

Anche nella categoria neutra si osservano scostamenti in entrambe le direzioni, con sezioni percepite come chiaramente polarizzate.

Nel complesso, circa un quarto delle sezioni polarizzate non viene percepito in modo univoco. L'attribuzione di genere a livello linguistico mostra quindi una componente interpretativa non trascurabile, con margini di ambiguità legati alla configurazione dei tratti testuali.

4.2 Prestazioni dei modelli

4.2.1 GPT-4.1-mini

L'analisi complessiva dei gender score medi restituisce una media globale pari a -0.135, indicando una lieve inclinazione verso la polarità femminile. La deviazione standard è pari a 0.642 e l'intervallo osservato copre l'intera scala teorica [-2; +2], segnalando la presenza di casi fortemente polarizzati in entrambe le direzioni. Nel complesso, il modello si mantiene in prossimità della neutralità, ma mostra una moderata asimmetria aggregata verso il polo femminile (Figura 2).

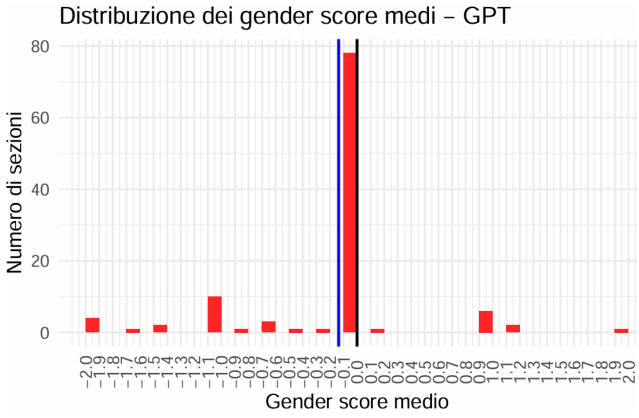

Figura 2: Distribuzione dei gender score medi delle sezioni valutate da GPT. La linea verticale indica lo zero della scala [-2, +2].

Tabella 2: Statistiche descrittive per categoria testuale (GPT)

Categoria	N sezioni	Score medio	Deviazione std
F	41	-0.380	0.595
M	39	0.179	0.629
N	31	-0.206	0.567

L'analisi disaggregata (Tabella 2) per categoria evidenzia una distinzione coerente tra i gruppi testuali. I testi femminili presentano uno score medio pari a -0.380, mostrando una polarizzazione netta verso la direzione attesa. I testi maschili registrano una media pari a 0.179, positiva ma di entità più contenuta. I testi neutri risultano leggermente spostati verso la polarità femminile (-0.206), indicando uno scostamento medio rispetto alla neutralità teorica. Le deviazioni standard risultano simili tra le tre categorie (0.567–0.629), suggerendo una variabilità interna comparabile.

L'analisi delle singole sezioni evidenzia inoltre alcune inversioni di polarità caratterizzate da una chiara direzionalità. Nella categoria neutra emergono casi di femminilizzazione stabile, con sezioni che raggiungono punteggi medi pari a -2 senza variabilità tra le run, mentre non si osservano episodi di mascolinizzazione. Nella categoria maschile si registrano quattro sezioni con punteggi negativi (fino a -1), indicando uno spostamento verso la polarità femminile; al contrario, nella categoria femminile non emergono casi di maschilizzazione. Nel complesso, i disallineamenti risultano prevalentemente orientati verso il polo femminile.

4.2.2 Gemini-2.5-flash

L'analisi complessiva dei gender score medi restituisce una media globale pari a 0.07, quindi prossima alla neutralità, accompagnata da una deviazione standard pari a 0.955, indicativa di una dispersione elevata. L'intervallo osservato copre l'intera scala teorica [-2; +2], evidenziando la presenza di sezioni fortemente polarizzate in entrambe le direzioni. Nel complesso, il modello utilizza l'intera ampiezza della scala e manifesta una distribuzione meno compressa attorno allo zero rispetto a una neutralità stretta (Figura 3).

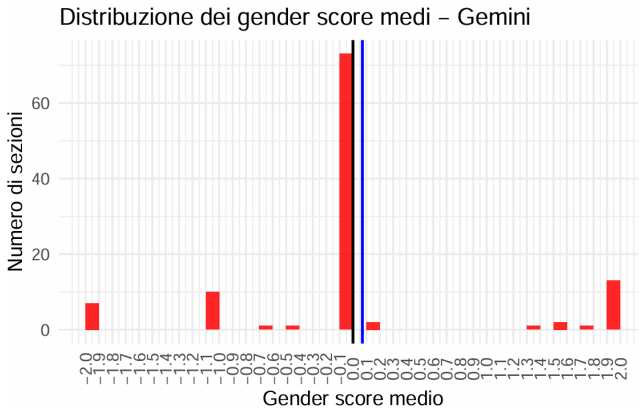

Figura 3: Distribuzione dei gender score medi delle sezioni valutate da Gemini. La linea verticale indica lo zero della scala [-2, +2].

Tabella 3: Statistiche descrittive per categoria testuale (Gemini)

Categoria	N sezioni	Score medio	Deviazione std
F	41	-0.390	0.657
M	39	0.790	1.027
N	31	-0.226	0.617

L'analisi disaggregata per categoria (Tabella 3) mostra una chiara separazione tra testi femminili e maschili. I testi femminili presentano una media pari a -0.390, evidenziando una polarizzazione marcata verso la direzione attesa. I testi maschili registrano una media pari a 0.790, mostrando una polarizzazione positiva ancora più intensa. I testi neutri si collocano in prossimità dello zero (-0.226), mostrando una polarizzazione verso il genere femminile. Le deviazioni standard risultano elevate nelle categorie polarizzate, indicando una variabilità interna significativa.

L'analisi delle singole sezioni evidenzia alcuni casi di disallineamento, con inversioni di polarità sia nella categoria femminile sia in quella maschile. Tali inversioni risultano tuttavia numericamente contenute rispetto al totale delle sezioni. Nella categoria neutra si osservano episodi di polarizzazione in entrambe le direzioni, suggerendo una sensibilità del modello ai segnali linguistici anche in assenza di marcatori forti. Nel complesso, la struttura delle assegnazioni appare coerente, con una tendenza alla polarizzazione netta delle categorie teoricamente connotate.

4.2.3 DeepSeek-chat

L'analisi complessiva dei gender score medi restituisce una media globale pari a 0.059, valore prossimo alla neutralità. La deviazione standard è pari a 0.488, indicando una dispersione moderata. L'intervallo osservato non si estende lungo l'intera scala teorica, ma solo nell'intervallo [-1; +1.4], evidenziando una polarizzazione moderata, senza l'utilizzo degli estremi teorici. Nel complesso, il

modello mantiene una distribuzione centrata attorno allo zero, con una leggera inclinazione verso la polarità femminile (Figura 4).

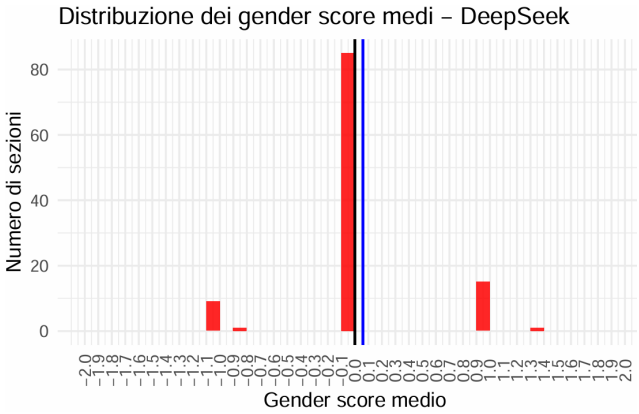

Figura 4: Distribuzione dei gender score medi delle sezioni valutate da DeepSeek. La linea verticale indica lo zero della scala [-2, +2].

Tabella 4: Statistiche descrittive per categoria testuale (DeepSeek)

Categoria	N sezioni	Score medio	Deviazione std
F	41	-0.190	0.392
M	39	0.421	0.515
N	31	-0.065	0.250

L'analisi disaggregata per categoria (Tabella 4) mostra una distinzione coerente tra testi femminili e maschili. I testi femminili presentano una media pari a -0.190, evidenziando una polarizzazione stabile verso la direzione attesa. I testi maschili registrano una media pari a 0.421, mostrando una polarizzazione positiva leggermente superiore. I testi neutri si collocano in prossimità dello zero (-0.065), risultando complessivamente allineati alla neutralità teorica. Le deviazioni standard risultano simili tra le categorie, suggerendo una variabilità interna contenuta e relativamente uniforme.

L'analisi delle singole sezioni evidenzia alcuni casi di disallineamento, con inversioni di polarità presenti sia nella categoria femminile sia in quella maschile. Tali episodi risultano tuttavia limitati rispetto al totale delle sezioni considerate. Nella categoria neutra si osservano occasionali spostamenti verso entrambe le polarità, senza una direzionalità dominante. Nel complesso, la struttura delle assegnazioni appare bilanciata e coerente con la distinzione tripartita del dataset.

4.3 Confronto

4.3.1 Confronto tra modelli

Per garantire un confronto equo tra modelli e valutazioni umane, l'analisi comparativa considera esclusivamente le 111 sezioni ritenute valide, assicurando che entrambe le valutazioni siano allineate sugli stessi dati. L'analisi evidenzia differenze nella distribuzione dei punteggi lungo la scala di genere. Sul piano aggregato, Gemini presenta la dispersione più elevata ($\sigma = 0.955$), con una distribuzione ampia e una marcata polarizzazione nelle categorie teoricamente connotate. GPT mostra una distribuzione più contenuta ($\sigma = 0.642$), caratterizzata da una lieve asimmetria sistematica verso la polarità femminile. DeepSeek si colloca in posizione intermedia in termini di media globale (0.059), ma con la variabilità più contenuta tra i tre modelli ($\sigma = 0.488$), mantenendo una distribuzione complessivamente centrata attorno allo zero.

Le differenze non riguardano soltanto l'ampiezza della dispersione, ma anche la configurazione complessiva dei pattern di attribuzione. Gemini tende a utilizzare in modo più frequente gli estremi della scala, in particolare nella categoria maschile, mentre GPT mostra una polarizzazione più attenuata e una maggiore concentrazione dei punteggi in prossimità della neutralità. DeepSeek adotta un profilo più moderato, con minore estensione verso le polarità estreme.

Tali divergenze risultano confermate dall'analisi di correlazione lineare tra i modelli (Tabella 5). Gemini e DeepSeek presentano una forte correlazione ($r = 0.77$), indicando una significativa convergenza nei pattern di distribuzione degli score per sezione. GPT mostra correlazioni decisamente inferiori ($r = 0.12$ e $r = 0.10$), evidenziando un pattern di attribuzione meno convergente rispetto agli altri due sistemi.

Tabella 5: Coefficienti di correlazione lineare di Pearson tra i modelli

Confronto	r
Gemini – DeepSeek	0.77
GPT – Gemini	0.12
GPT – DeepSeek	0.10

Nel complesso, i tre modelli si differenziano non soltanto per intensità della polarizzazione, ma per ampiezza della dispersione e grado di convergenza reciproca nei pattern di attribuzione dei punteggi.

Tabella 6: Sintesi descrittiva dei profili comportamentali dei modelli

Modello	Dispersione	Polarizzazione
GPT	Intermedia	Lieve asimmetria verso F
Gemini	Elevata	Marcata su F e M
DeepSeek	Ridotta	Moderata e centrata

I tre modelli risultano complessivamente stabili rispetto alla temperatura, che non altera in modo sostanziale la distribuzione aggregata dei punteggi, suggerendo che i pattern osservati riflettano configurazioni strutturali dei modelli piuttosto che fluttuazioni stocastiche.

4.3.2 Confronto tra modelli e percezione umana

Il confronto tra i modelli e la percezione umana evidenzia differenze sia sul piano aggregato sia nella distribuzione per categoria testuale. A livello globale, la

media dei punteggi umani risulta sostanzialmente neutra (-0.012), mentre GPT mostra una lieve inclinazione verso la polarità femminile (-0.135). Gemini e DeepSeek mantengono medie prossime allo zero (rispettivamente 0.07 e 0.059), pur differenziandosi per ampiezza della dispersione.

L'analisi per categoria consente di osservare più chiaramente tali differenze. Nella categoria femminile, tutti i modelli attribuiscono punteggi negativi coerenti con l'etichettatura teorica, con valori simili a quelli umani. Nella categoria maschile, Gemini presenta la polarizzazione più marcata (0.790), mentre GPT mostra un'intensità più contenuta (0.179) rispetto alla media umana (0.446). DeepSeek si colloca in posizione intermedia (0.421), con una separazione tra le categorie simile a quella osservata nella percezione umana.

Per quanto riguarda le sezioni neutre, gli umani mantengono una media prossima allo zero (-0.081). GPT e Gemini mostrano uno spostamento medio verso il polo femminile (rispettivamente -0.206 e -0.226), mentre DeepSeek mantiene un valore più vicino alla neutralità (-0.065).

L'allineamento complessivo tra modelli e percezione umana è confermato dall'analisi di correlazione lineare di Pearson (Tabella 7). DeepSeek risulta il modello maggiormente correlato con i punteggi umani ($r = 0.61$), seguito da Gemini ($r = 0.59$) e GPT ($r = 0.49$).

Tabella 7: Coefficienti di correlazione lineare di Pearson tra modelli e percezione umana

Confronto	r
Umano – DeepSeek	0.61
Umano – Gemini	0.59
Umano – GPT	0.49

Accanto alle tendenze aggregate emergono specifici casi di polarizzazione condivisa tra percezione umana e modelli. Alcune sezioni teoricamente neutre risultano fortemente femminilizzate in tutti i sistemi considerati (Tabella 8).

Tabella 8: Sezioni con maggiore polarizzazione o disallineamento e il loro score medio

Sezione	Atteso	Umano	GPT	Gemini	DeepSeek
N3_1	0	-1.28	-2.00	-2.00	-1.00
N15_2	0	-1.00	-2.00	-2.00	-1.00
N3_3	0	-0.17	-1.40	-2.00	0.00
N7_1	0	-0.27	-1.00	-1.00	0.00
N2_3	0	+0.71	0.00	0.00	0.00
M3_3	+1	-1.00	-1.00	-1.00	0.00

Ad esempio, la sezione N3_1 presenta punteggi negativi marcati sia nella valutazione umana sia nei tre modelli:

> *Il primo dato che balza all'occhio è quello delle vittime di sesso femminile. Dal 1 gennaio 2023 al 31 luglio 2024 sono state 175. Conosciamo bene purtroppo i fatti di cronaca dietro queste storie, così come sappiamo che il 31,5% delle donne in Italia ha subito nel corso della propria vita una qualche forma di violenza fisica o sessuale.*

Un andamento analogo si osserva nella sezione N15_2:

> *La donna ha trovato il coraggio di denunciare l'aggressione solo la mattina seguente. I carabinieri, dopo aver ricevuto il racconto, hanno allertato il 118 e l'hanno trasferita all'ospedale di Galliera. Qui sono stati eseguiti i primi esami e test, e la donna ha parlato con una psicologa.*

In entrambi i casi, la presenza esplicita di riferimenti a soggetti femminili e a tematiche legate alla violenza di genere si associa a una polarizzazione verso il polo femminile, con valori più estremi in GPT e Gemini rispetto a DeepSeek.

Per quanto riguarda l'interpretazione maschile di testi neutri è un fenomeno legato solo alla valutazione umana, più contenuto della femminilizzazione. Il testo più mascolinizzato è N2_3.

Un fenomeno parzialmente diverso si osserva nella sezione M3_3, teoricamente appartenente alla categoria maschile ma femminilizzata sia dagli umani sia da GPT e Gemini:

> *Invece di risultare un po' piatto (come può accadere a volte con la monocromia), il mix di colori è un ottimo modo per rendere un outfit interessante, aggiungendo l'elemento cruciale e apparentemente spontaneo del "l'ho appena indossato".*

In questo caso, la convergenza tra percezione umana e sistemi automatici evidenzia una reinterpretazione condivisa del contenuto testuale. Nel complesso, i casi esaminati mostrano che le differenze tra modelli e percezione umana riguardano non solo l'intensità dei punteggi assegnati, ma anche la distribuzione e la direzionalità delle attribuzioni nei singoli episodi. Le possibili implicazioni di tali differenze verranno discusse nel capitolo successivo.

5 Discussione

I risultati mostrano che GPT, Gemini e DeepSeek non operano in uno spazio interpretativo separato rispetto alla percezione umana, ma condividono con essa un nucleo comune di associazioni semantiche. Le divergenze osservate non riguardano la direzione generale delle attribuzioni di genere, bensì l'intensità con cui esse vengono espresse e la dispersione dei punteggi lungo la scala. Questo elemento è centrale: il problema non è se i modelli attivino associazioni di genere, ma quanto facilmente e con quale forza decidano di esplicitarle.

Alla luce del quadro teorico delineato nel Capitolo 2, il genere non è una proprietà intrinseca del testo, ma una costruzione discorsiva che emerge dall'interazione tra contenuto tematico, frame culturali e aspettative sociali. Se i modelli sono addestrati su corpora che incorporano

tali strutture simboliche, è coerente che condividano con gli umani le stesse linee di forza interpretative. In questo senso, i risultati non indicano l'esistenza di bias artificiali completamente autonomi rispetto al discorso sociale ma la riproduzione di configurazioni semantiche già presenti.

Le differenze tra i modelli emergono invece nella calibrazione. DeepSeek adotta una strategia marcatamente moderata: in presenza di segnali ambigui tende a rimanere in prossimità della neutralità, limitando l'uso degli estremi. Gemini, al contrario, mostra una maggiore propensione a esplicitare polarizzazioni quando intercetta domini semanticamente connotati. GPT presenta un profilo meno sovrapponibile agli altri due, con una gestione della polarizzazione che non coincide pienamente né con la moderazione di DeepSeek né con l'espansività di Gemini.

Queste differenze non possono essere interpretate come semplici variazioni casuali. La stabilità osservata rispetto alla variazione della temperatura indica che i pattern rilevati riflettono configurazioni classificatorie strutturali, non fluttuazioni stocastiche della generazione. Ciò rafforza l'idea che ciascun modello incorpori una soglia decisionale propria nella gestione della polarizzazione.

Particolarmente significativo è il fatto che DeepSeek e Gemini risultino più convergenti tra loro rispetto alla loro somiglianza con GPT, nonostante appartengano a contesti industriali differenti. Questo risultato suggerisce che la similarità comportamentale non dipenda dalla sola appartenenza a uno stesso ecosistema tecnologico. Suggerisce quindi che le strutture associative apprese possano convergere anche in modelli sviluppati separatamente, probabilmente in virtù della natura globale e culturalmente stratificata dei dati di addestramento. Allo stesso tempo, la divergenza di GPT indica che scelte specifiche di calibrazione e soglie interne possono incidere più della provenienza aziendale.

È inoltre rilevante osservare che DeepSeek, pur essendo rilasciato con licenza open, non mostra un comportamento più estremo o meno controllato rispetto ai modelli proprietari. Anzi, risulta quello maggiormente allineato alla percezione umana aggregata. Questo dato indebolisce una possibile aspettativa secondo cui apertura del modello e minore controllo industriale possano tradursi in una gestione meno calibrata delle associazioni di genere. Nel perimetro del task analizzato, la distinzione open vs closed non emerge come fattore determinante.

Un elemento trasversale riguarda il ruolo della neutralità. In DeepSeek, essa funziona come strategia prudenziale; in Gemini, viene superata più facilmente in presenza di domini culturalmente connotati; in GPT, la sua gestione contribuisce a un profilo meno convergente. In linea con il Capitolo 2, la neutralità non deve essere interpretata come assenza di genere, ma come esito situato di un processo interpretativo. I casi di disallineamento mostrano pattern ricorrenti: attivazione tematica di ambiti simbolicamente associati a uno dei poli, salienza lessicale di riferimenti di genere e testi caratterizzati da ambiguità strutturale. L'attribuzione emerge dunque dall'interazione tra segnali linguistici e frame culturali, non da una proprietà fissa del testo.

Nel complesso, i risultati suggeriscono che la questione del bias nei Large Language Models non possa essere ridotta alla presenza o assenza di polarizzazione. Essa riguarda piuttosto la soglia con cui le associazioni vengono attivate e la calibrazione dell'intensità con cui vengono espresse. GPT, Gemini e DeepSeek condividono un terreno semantico comune, ma differiscono nel modo in cui decidono di uscire dalla neutralità. È in questa modulazione — più che nella direzione delle attribuzioni — che si gioca la distanza tra modelli e percezione umana. Lo studio presenta alcuni limiti: la composizione prevalentemente giovane del campione umano, l'utilizzo di versioni "mini" dei modelli, l'assenza di accesso ai dati di addestramento e alle strategie di alignment e la natura correlazionale dell'analisi, che non consente inferenze causali. Tali limiti delimitano l'interpretazione, ma non ne riducono la coerenza interna.

I risultati suggeriscono che la questione del bias nei modelli linguistici non si esaurisca nella presenza di associazioni di genere, ma riguardi soprattutto la soglia e l'intensità con cui esse vengono espresse.

6 Conclusioni

L'analisi condotta sul dataset italiano ha evidenziato che GPT, Gemini e DeepSeek condividono con la percezione umana un nucleo comune di associazioni di genere, ma si differenziano nella soglia e nell'intensità con cui tali associazioni vengono espresse. Le divergenze osservate non indicano universi semantici separati, bensì modalità differenti di calibrazione della polarizzazione. In questo senso, la questione del bias nei modelli linguistici emerge meno come problema di direzione e più come problema di gestione dell'intensità e della neutralità in condizioni di ambiguità.

Lo studio presenta alcuni limiti. Il campione umano risulta prevalentemente giovane, elemento che potrebbe influenzare le associazioni attivate. L'analisi è di natura correlazionale e non consente inferenze causali sui meccanismi interni dei modelli. Inoltre, l'assenza di accesso ai dati di addestramento e alle strategie di alignment limita la possibilità di spiegare in modo diretto le differenze osservate. Sono state infine utilizzate versioni "mini" dei modelli, adeguate al task di classificazione sintetica ma non necessariamente rappresentative di configurazioni più ampie.

Sviluppi futuri potrebbero includere l'ampliamento del dataset a ulteriori domini tematici, l'estensione del campione umano a fasce anagrafiche più diversificate e il confronto con modelli linguistici di nuova generazione o con ulteriori sistemi di intelligenza artificiale. Tali approfondimenti permetterebbero di verificare se le dinamiche osservate costituiscano caratteristiche strutturali dei Large Language Models o configurazioni specifiche dei modelli analizzati nel presente studio.

Disponibilità dei dati e del codice

Il dataset ampliato, la pipeline di valutazione implementata in linguaggio Python, gli script di analisi statistica e i risultati completi delle run sperimentali sono disponibili pubblicamente nel repository GitHub del progetto:

https://github.com/elisafamulari-coder/GenderSte-

Il repository include inoltre la documentazione necessaria per replicare l'intero processo sperimentale, incluse le configurazioni dei parametri utilizzati per ciascun modello.

Riferimenti bibliografici

[1] Yuntao Bai, Saurav Kadavath, Sandipan Kundu, Amanda Askell, Jackson Kernion, Andy Jones, Anna Chen, Anna Goldie, Azalia Mirhoseini, Sam McCandlish, et al. Constitutional ai: Harmlessness from ai feedback. *arXiv preprint arXiv:2212.08073*, 2022.

[2] Emily M Bender, Timnit Gebru, Angelina McMillan-Major, and Shmargaret Shmitchell. On the dangers of stochastic parrots: Can language models be too big? In *Proceedings of the 2021 ACM conference on fairness, accountability, and transparency*, pages 610–623, 2021.

[3] Davide Biasion, Alessandro Fabris, Gianmaria Silvello, and Gian Antonio Susto. Gender bias in italian word embeddings. In *Proceedings of the Seventh Italian Conference on Computational Linguistics (CLiC-it 2020)*, pages 32–39, 2020.

[4] Tolga Bolukbasi, Kai-Wei Chang, James Y Zou, Venkatesh Saligrama, and Adam T Kalai. Man is to computer programmer as woman is to homemaker? debiasing word embeddings. *Advances in neural information processing systems*, 29, 2016.

[5] Alice H Eagly and Wendy Wood. Social role theory. *Handbook of theories of social psychology*, 2(9):458–476, 2012.

[6] Norman Fairclough. Language and power, 1989. *Harlow: Longman*, 2001.

[7] Google. Google ai principles. `https://ai.google/principles/`, 2018. Accessed: 2026-02-24.

[8] R Hausmann, LD Tyson, and S Zahidi. The global gender gap report: World economic forum, 2009.

[9] Margaret Mitchell, Simone Wu, Andrew Zaldivar, Parker Barnes, Lucy Vasserman, Ben Hutchinson, Elena Spitzer, Inioluwa Deborah Raji, and Timnit Gebru. Model cards for model reporting. In *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAT* '19)*, pages 220–229, 2019.

[10] OpenAI. Gpt-4 system card. `https://cdn.openai.com/papers/gpt-4-system-card.pdf`, 2023. Accessed: 2026-02-24.

[11] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems*, 35:27730–27744, 2022.

[12] Martino Scagnet. Sviluppo e validazione di un dataset in italiano per l'analisi di stereotipi di genere nei documenti testuali, 2023.

[13] Gijsbert Stoet. Psytoolkit: A software package for programming psychological experiments using linux. *Behavior research methods*, 42(4):1096–1104, 2010.

[14] Gijsbert Stoet. Psytoolkit: A novel web-based method for running online questionnaires and reaction-time experiments. *Teaching of Psychology*, 44(1):24–31, 2017.

[15] Henri Tajfel. Social identity and intergroup behaviour. 2010.

[16] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.

[17] Federico Vismara. Un dataset italiano per l'analisi degli stereotipi di genere nei documenti testuali, 2024.

[18] Laura Weidinger, John Mellor, Maribeth Rauh, Conor Griffin, Jonathan Uesato, Po-Sen Huang, Myra Cheng, Amelia Glaese, Borja Balle, Atoosa Kasirzadeh, et al. Ethical and social risks of harm from language models. *arXiv preprint arXiv:2112.04359*, 2021.